Guía práctica del Taller 3

TrackAmazonas Equipo 4

Este documento permite ejecutar el laboratorio, reconocer sus resultados y explicar la solución. La base trabaja sin servicios externos: SQLite, DuckDB y Parquet. La V3 sigue siendo la fuente operacional de continuidad y puede importarse cuando Docker esté disponible.

Preparación antes de la clase

Extraer el ZIP en una carpeta propia, por ejemplo D:\ITM\20262\TAeBD\Taller 3\TrackAmazonas_Lakehouse. Abrir PowerShell allí. Tener Python 3.11 o 3.12 de 64 bits. Reservar alrededor de 1 GB para el ensayo grande.

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe main.py
```

La tercera línea equivale a python main.py si el entorno está activado. Usar el ejecutable completo evita cambiar la política de PowerShell. La instalación necesita Internet; el perfil académico posterior funciona localmente.

Qué debería ocurrir

Se genera una fuente académica, aparece un lote Bronze, luego Silver, Gold, ocho resultados SQL y tres comparaciones. Al final se imprime PASS con una carpeta de evidencia. La ejecución rápida medida de 50.000 originales tardó 17,606 segundos; no es un tiempo garantizado.

Ensayo	Bronze	Silver / Gold
Rápido 50.000 originales	50.550	49.698
Referencia 500.000 originales	505.500	496.989

Si hay error, detener el recorrido y leerlo. Cada fallo guarda failure.json; el snapshot anterior sigue activo. No comparar los conteos del perfil rápido con los del ensayo de 500.000.

Ejecución y archivos del proyecto

Del comando al resultado visible

```
.\.venv\Scripts\python.exe main.py --rows 500000 --repeats 9
.\.venv\Scripts\python.exe -m unittest discover -s tests -v
```

El ensayo grande conserva la semilla 42 y mide nueve repeticiones. Las siete pruebas base deben terminar con OK; la prueba Delta opcional queda omitida. El perfil grande y el rápido fueron validados; la repetición del fixture comprueba idempotencia.

Archivo	Qué explicar al señalarlo
main.py	Orquesta y publica solamente tras los controles
source.py	Genera datos del dominio con defectos intencionales
extract.py	Copia raw y conserva un snapshot Bronze
transform_silver.py	Decide tipos, válidos, duplicados y cuarentena
transform_gold.py	Materializa la estrella y vincula la versión SCD correcta
analyze.py	Aplica las ocho preguntas SQL
benchmark.py	Comprueba resultados y mide tiempos reales
export_v3.py	Lee Mongo a través de Docker
benchmark_mongo_v3.py	Comparación opcional con el motor operacional real

No ocultar el propósito de los defectos

La fuente conserva fechas inválidas, nulos, coordenadas incorrectas, repeticiones y payloads conflictivos para ejercitar Silver. Son anomalías de calidad distintas de los desvíos espaciales válidos. Un desvío válido se mantiene en los hechos; una coordenada imposible se audita como descarte.

Los CSV de consultas son salidas analíticas, no instrucciones para construir el pipeline. Los archivos JSON documentan qué corrida produjo los resultados. El código y los SQL pertenecen al repositorio; los grandes datos generados pueden reconstruirse.

Cómo inspeccionar las tres zonas

Mostrar datos y controles sin mezclar snapshots

```
Get-Content lakehouse\current.json
Get-ChildItem lakehouse -Recurse -Filter *.parquet
$estadoLake = Get-Content lakehouse\current.json -Raw |
  ConvertFrom-Json
Get-Content (Join-Path $estadoLake.silver 'reporte_calidad.txt')
```

Bronze

Mostrar position_events.parquet y vessel_history.parquet del lote indicado. Son valores raw con metadatos de fuente, batch y extracción. Su manifest.json contiene hashes. Un lote publicado no se modifica para corregir un error de transformación.

Silver

Mostrar las filas válidas y quarantine.parquet. Abrir reporte_calidad.txt: Bronze = Silver + descartes. En el perfil grande: 505.500 = 496.989 + 8.511. Los 1.493 nulos opcionales de velocidad permanecen NULL. Las fechas y coordenadas obligatorias defectuosas no entran a Gold.

Gold

Mostrar las cuatro dimensiones y fact_telemetria/year=2026/month=... . La estrella guarda un evento por fila. dim_embarcacion contiene 880 versiones, pero son 800 barcos: las versiones no aumentan el tamaño de la flota.

fact_unpartitioned.parquet es el control del benchmark y no otra fuente que deba sumarse al hecho. agg_rio_mes es un agregado separado. Leer todos los Parquet sin distinguir sus propósitos causaría dobles conteos.

Manifestación de idempotencia

Ejecutar main.py por segunda vez. Señalar Bronze reutilizado y Silver/Gold reutilizados. Los conteos y las claves son iguales; cambia la carpeta de evidencia porque se volvió a medir. Si cambió la fuente, el nuevo lote y su snapshot tienen otro identificador.

Consultas para la demostración

Dos consultas en vivo y seis preguntas adicionales

```
.\.venv\Scripts\python.exe -m scripts.analyze --query 2
.\.venv\Scripts\python.exe -m scripts.analyze --query 5
```

Q2 Retrasos de llegada

Explicar que ingestion_time menos event_time incluye el atraso offline. El promedio muestra el efecto acumulado de la cola; p95 y p99 describen partes diferentes de la distribución. Un p95 de tres segundos puede coexistir con un p99 de cinco horas si el grupo afectado representa menos del 5% de muestras.

Q5 Historia SCD Tipo 2

Mostrar las dos versiones de TA-001. En el ensayo grande hay 373 muestras del Operador A y 248 del B; en el rápido hay 38 y 24. El evento exactamente en valid_from de la nueva versión corresponde a ella. El tiempo de recepción no reescribe su historia.

Consulta	Qué trabaja	Precaución
Q1	Volumen y anomalías por río/mes	Cuenta muestras, no incidentes
Q3	Rutas y velocidad media	Mostrar cantidad de velocidades válidas
Q4	Barcos para revisión	Tasa exige mínimo de muestras
Q6	Tardíos por fecha de captura	Observados no equivale a esperados

Los SQL completos están en queries/. Cambiar --query por un número de 1 a 8 permite ejecutarlos individualmente. Si se usó --root ensayo_nuevo en main, agregar --root ensayo_nuevo al comando de consulta.

Narración sugerida

«Esta consulta responde una pregunta del negocio. El resultado describe nuestra muestra académica. Aquí mostramos el numerador, el denominador y el contexto temporal. Para decidir sobre una ruta real necesitamos revisar calidad, cobertura y reglas.»

Benchmark y planes

Cómo defender los tiempos sin exagerar

```
$estadoLake = Get-Content lakehouse\current.json -Raw |
  ConvertFrom-Json
Get-Content (Join-Path $estadoLake.evidence 'benchmark.csv')
Get-Content (Join-Path $estadoLake.evidence 'plans\opt1_partitioned.txt')
```

Referencia grande	Antes / después ms	Interpretación
Fuente / Gold	3.525,896 / 122,478	Ratio 28,79; preparación y motores distintos
Monolítico / particionado	10,806 / 15,158	Particionado más lento en este ensayo
Detalle / agregado	89,393 / 11,238	Ratio 7,95; preparación fuera del cronómetro

Los tiempos de la pantalla son los de la corrida activa, no necesariamente los de esta tabla. Se miden medianas de nueve repeticiones en la referencia. Las pruebas verifican que los resultados coinciden; si no, se rechaza el benchmark.

Qué señalar en EXPLAIN ANALYZE

READ_PARQUET y Projections muestran columnas utilizadas. File Filters y Scanning Files: 1/3 muestran que febrero evita otros archivos. El monolítico también filtra y está ordenado. Hay pruning efectivo y, aun así, un costo fijo puede dominar la consulta.

El agregado mensual tiene nueve filas. Por eso responde rápido a su propia pregunta, pero no permite consultar posiciones individuales. Debe actualizarse con meses afectados por tardíos y recomponer medias desde numeradores y denominadores.

Respuesta oral ante una pregunta de rendimiento

«La comparación es real y sus resultados coinciden. Incluye el diseño aplicado: conversión de tipos y regla en la fuente, métricas preparadas y lectura vectorizada en Gold. No la presentamos como un experimento que aisló exclusivamente el formato columnar.»

Importar la V3 y medir Mongo

Continuidad operacional opcional con pasos explícitos

Requisito: Docker Desktop activo y una corrida V3 cerrada con PASS. El ID 0f33dcf80937 es un ejemplo de la evidencia del equipo; reemplazarlo si se utiliza otra corrida. Ejecutar desde la raíz del nuevo proyecto.

```
.\.venv\Scripts\python.exe -m scripts.export_v3
  --compose-dir "D:\ITM\20262\TAeBD\Taller 2\TrackAmazonas_Demo_V3"
  --run-id 0f33dcf80937
  --output source\v3_exports\run_0f33dcf80937.jsonl
```

Las líneas anteriores se muestran separadas para facilitar lectura. Copiar el comando completo en una línea desde docs/COMANDOS.txt. El script entra al contenedor app, consulta Mongo con sesión snapshot y conserva BSON Extended JSON. No modifica la V3.

```
.\.venv\Scripts\python.exe main.py --input-v3
  source\v3_exports\run_0f33dcf80937.jsonl
```

Este perfil crea un espejo SQLite y luego las tres zonas. raw_extended_json conserva el documento completo, incluso campos que no se usan en Gold. El catálogo se infiere sin atributos de operador; por eso no se fabrica un cambio SCD.

```
.\.venv\Scripts\python.exe -m scripts.benchmark_mongo_v3
  --compose-dir "D:\ITM\20262\TAeBD\Taller 2\TrackAmazonas_Demo_V3"
  --run-id 0f33dcf80937
```

La medición real requiere exactamente las mismas identidades que el Gold activo y el mismo agregado. Si difieren, el script falla. Guarda benchmark_mongo_real.json; incluir sus cifras y contexto en la entrega si se ejecuta con éxito.

Estos adaptadores están preparados pero pendientes de validación con la instancia activa. El test de importación usa un fixture. No sustituir una medición Mongo por la tabla de SQLite ni por el PASS del taller anterior.

Exposición de los cinco integrantes

Distribución propuesta para 20 o 15 minutos

Responsable	Versión 20 min	Versión 15 min	Contenido
Integrante 1	00-03	00-02	Problema y alcance analítico
Integrante 2	03-06	02-04	Grano, estrella y SCD2
Integrante 3	06-09	04-06	Pipeline y calidad
Integrante 4	09-12	06-08	Consultas, benchmark y límites
Integrante 5	12-18	08-13	main.py, Parquet y dos SQL en vivo
Cierre del equipo	18-20	13-15	Hallazgos y producción

La guía práctica establece 20 minutos; confirmar con el docente la duración definitiva. Todos deben poder responder sobre cualquier componente, aunque tengan una parte asignada.

Secuencia del demostrador

Antes del cronómetro: instalar dependencias y abrir terminales en la carpeta. Durante la demo: ejecutar main.py, señalar PASS y rutas; abrir el reporte Silver, mostrar archivos Parquet, ejecutar Q2 y Q5, y cerrar con una comparación medida. Los ensayos de 500.000 y las instalaciones deben hacerse previamente.

Frases para enlazar la defensa

Integrante 1: «Extendemos el tracking con una capa para estudiar el historial y los retrasos». Integrante 2: «Cada fila es un evento, y su versión de barco corresponde al momento de captura». Integrante 3: «Podemos reconciliar lo que conservamos y cada descarte».

Integrante 4: «Todas las comparaciones validan igualdad; una optimización puede no mejorar el tiempo con archivos pequeños». Integrante 5: «La ejecución publica un snapshot validado. Estas dos consultas muestran demora e historia».

Qué preparar para GitHub

Publicar código, README, docs, SQL y evidence_referencia. Desde una carpeta clonada nueva instalar y ejecutar el comando. No subir .venv ni SQLite ni todos los snapshots grandes; la guía permite instrucciones para regenerarlos. Guardar el enlace real del repositorio para la entrega.

Preguntas y recuperación

Guía de defensa individual y diagnóstico

¿Por qué una estrella y no todo en una sola tabla?

La estrella hace explícito contexto, grano e historia; permite reutilizar dimensiones. Una tabla ancha puede ser útil físicamente, pero no elimina la necesidad de asignar cada evento a su versión temporal correcta.

¿Por qué SCD2 en lugar de sobrescribir el operador?

Sobrescribir perdería qué operador estaba vigente cuando se capturó el GPS. SCD2 crea una clave distinta, conserva intervalos y vincula el hecho por event_time. Para la V3 no inventamos el catálogo que no existe.

¿Por qué los reintentos no aumentan los eventos?

Se deduplican por identidad y contenido. Si una identidad válida presenta dos payloads distintos, ambas versiones quedan en revisión. La publicación solo consulta el snapshot activo, sin mezclar lotes.

¿Tiene ACID este lakehouse local?

SQLite y DuckDB tienen sus propias transacciones; los Parquet separados no conforman una transacción distribuida ni un formato de tabla transaccional. Los manifiestos y un escritor controlan la publicación académica. Delta o Iceberg aportan otras garantías que deben evaluarse en producción.

¿Por qué la partición resultó más lenta?

Con tres archivos pequeños domina el costo fijo. El monolítico ordenado ya descarta grupos. Mostramos el plan y la medida; al crecer volumen se debe reevaluar tamaño, compactación y filtros.

Si algo falla durante la demo

ModuleNotFoundError: comprobar el Python .venv y la instalación. No hay current.json: ejecutar primero main.py. FileExistsError del lock: confirmar si hay otro pipeline activo. Hash distinto: conservar la evidencia y usar un --root nuevo para aislar el ensayo. Error Docker: revisar Desktop y V3; usar el perfil local.

El laboratorio deja failure.json y conserva la publicación anterior. Si la nueva corrida no termina, mostrar el estado real y la evidencia de referencia identificada como previa. No modificar los conteos ni decir que una evidencia anterior pertenece a la ejecución que falló.

Aportes consolidados y reporte

Qué mostrar de la V2 y cómo defender su alcance

Resumen horario y rutas

```
.\.venv\Scripts\python.exe -m scripts.analyze --query 7
.\.venv\Scripts\python.exe -m scripts.analyze --query 8
```

Q7 usa el nuevo agregado por hora, versión de barco, río y ruta. Mostrar que las muestras suman lo mismo que el detalle y que la media utiliza sumas y cantidades. Q8 añade percentiles de demora por ruta. El muestreo usa ráfagas de 30 s en cinco ventanas, sin afirmar continuidad entre ellas.

Abrir el reporte local

```
$estadoLake = Get-Content lakehouse\current.json -Raw |
  ConvertFrom-Json
$reporteLake = Join-Path $estadoLake.evidence 'reporte.html'
Start-Process (Join-Path (Get-Location) $reporteLake)
```

Navegar Resumen, Calidad, Consultas, Benchmark e Historia SCD. El filtro busca filas de la pestaña activa; cambiar de pestaña lo limpia. La vista previa muestra hasta 30 resultados y el CSV conserva la consulta completa. No hay actualización automática.

Preguntas sobre las propuestas externas

¿Por qué no copiar su SCD? Tiene campos de vigencia, pero cero cambios observables y una unión sin fecha. ¿Por qué no usar su speedup? Compara 20.200 raw con 19.964 hechos. ¿Por qué no sumar sus kilómetros? El intervalo por barco no es 30 s en ese generador.

Estado de Delta y herramientas

Delta queda como ejercicio experimental: su escritura local tuvo un error de permisos/renombrado. No decir que se validó time travel. dbt, Great Expectations y Metabase no se presentan como ejecutados en el núcleo. La guía práctica permite esta solución Python, Parquet y DuckDB con calidad demostrada.

La matriz de rúbrica y el análisis comparativo están en docs. El equipo conserva la obligación de publicar GitHub y de medir Mongo con la V3 activa si decide presentar esa integración.