TrackAmazonas Mini Lakehouse

Informe técnico consolidado V2 del Taller 3

Tópicos Avanzados en Bases de Datos. Institución Universitaria ITM, 2026-2S. Docente Roberto Carlos Rahamut Suteu. Preparado el 18 de octubre de 2026.

Integrantes: Cristian Valdes Díaz, Miguel Rendón Barrios, Johan Galeano Pulgarín, Fabian Diaz Hurtado y Juan Rodríguez Leguizamón.

Resumen de la solución

Extendemos TrackAmazonas con un ecosistema analítico local que conserva las muestras de telemetría, controla su calidad y las transforma en un modelo estrella. DuckDB consulta archivos Parquet en Bronze, Silver y Gold. La tabla de hechos mantiene un evento GPS válido por fila y la dimensión de embarcación implementa SCD Tipo 2 con consulta temporal.

La solución ejecutable incluye un perfil académico con SQLite como fuente row-store, datos sintéticos reproducibles y ocho consultas del dominio. Un segundo perfil importa documentos de la V3 desde MongoDB, conserva su contenido y prepara una medición contra ese motor. El pipeline se inicia con un comando y publica sus resultados al concluir las validaciones.

Resultado observado

Control	Referencia de 500.000 originales
Bronze	505.500 filas con defectos y reintentos
Silver y hechos Gold	496.989 eventos únicos válidos
Auditoría de descartes	8.511 filas conciliadas
Modelo	4 dimensiones; 880 versiones de 800 barcos
Historia SCD	80 embarcaciones con cambio de atributos
Pruebas locales	7 aprobadas; 1 Delta omitida

La ejecución 29b53ff4affb obtuvo PASS con el perfil académico V2. Se muestrean cinco fechas del trimestre en ráfagas GPS cada 30 segundos, sin afirmar captura continua durante 90 días. No es evidencia de capacidad de la flota real.

Alcance académico y continuidad

El tracking operativo de los talleres anteriores conserva su función. La nueva capa estudia volumen de muestras, retrasos, rutas e historia, sin sustituir las alertas en tiempo real. La guía práctica permite scripts Python sin dbt ni Airflow; por eso elegimos un laboratorio sencillo, reproducible y explicable.

Contraste de las propuestas

Aportes útiles y correcciones exigidas por la evidencia

El DOCX mejora objetivos, supuestos y estado de implementación; el ZIP aporta una base ejecutable y un mart horario; el diagrama comunica el flujo completo. Se contrastaron con la guía práctica, la rúbrica y el esquema real de la V3.

Elemento	Hallazgo observado	Decisión consolidada
SCD del ZIP	800 versiones para 800 barcos; cero cambios; merge solo por barco	Demostrar 80 cambios y lookup temporal
Benchmark del ZIP	20.200 raw frente a 19.964 hechos; sin igualdad de resultados	Medir una población validada idéntica
Resumen horario	Promedio de medias y distancia por intervalo fijo	Ponderar; no inventar distancia
Bronze	Glob de todas las extracciones	Consultar un lote y un snapshot exactos
Delta incluido	Commit versión 0; no demuestra dos versiones	Profundización separada, estado de prueba explícito

Ejemplo verificable del benchmark externo: Amazonas tiene 8.990 filas Bronze y 8.881 hechos Gold. Esa diferencia de población impide atribuir el ratio incluido a ejecutar la misma consulta sobre los mismos datos. No se adopta su speedup 2,55 como resultado comparable.

La V3 usa trackamazonas_v3_<run_id> y no implementa vessels, clientes, órdenes ni paquetes. heading y signal_quality del ZIP son ampliaciones sintéticas. El diagrama consolidado se limita a las fuentes y campos existentes; el catálogo académico se identifica como tal.

La guía práctica permite Python sin dbt ni Airflow. dbt/GX del DOCX son propuestas pendientes, no código del ZIP ni requisitos del núcleo. Metabase y DuckDB requieren un driver compatible; no se afirma conexión inmediata.

El detalle del contraste está en ANALISIS_COMPARATIVO.md y auditoria_propuestas.json, con los conteos leídos del ZIP y las decisiones por criterio de la rúbrica.

Requisitos y proceso analítico

Correspondencia con la guía y la rúbrica

Las cinco decisiones del diseño

Proceso: comportamiento de la telemetría fluvial y sus retrasos de recepción. Granularidad: un event_id válido por fila. Contexto: tiempo, embarcación, río y ruta. Medidas: conteos de muestras, banderas de anomalía y atraso, velocidad y retraso. Historia: cambios de operador y categoría de servicio en la embarcación.

Criterio	Evidencia en el proyecto
Modelo dimensional	Diagrama estrella PNG, 4 dimensiones, grano atómico y SCD2 con 80 cambios
Pipeline funcional	main.py, tres zonas Parquet, calidad Silver y descartes auditados
Consultas y benchmark	8 SQL del dominio; mismas poblaciones; tiempos, muestras y planes
Reproducibilidad	requirements fijados, README desde cero y ejecución con main.py
Adaptación y sustentación	Métricas fluviales, importación V3, límites y guía de exposición

Condiciones de aceptación

Bronze debe conservar todos los valores originales y ser inmutable. Silver debe reconciliar sus filas y justificar cada descarte. Gold debe tener un hecho único y exactamente una versión dimensional válida por evento. Las comparaciones solo se aceptan si sus resultados coinciden. Un fallo no debe reemplazar el snapshot activo.

Lectura de los documentos académicos

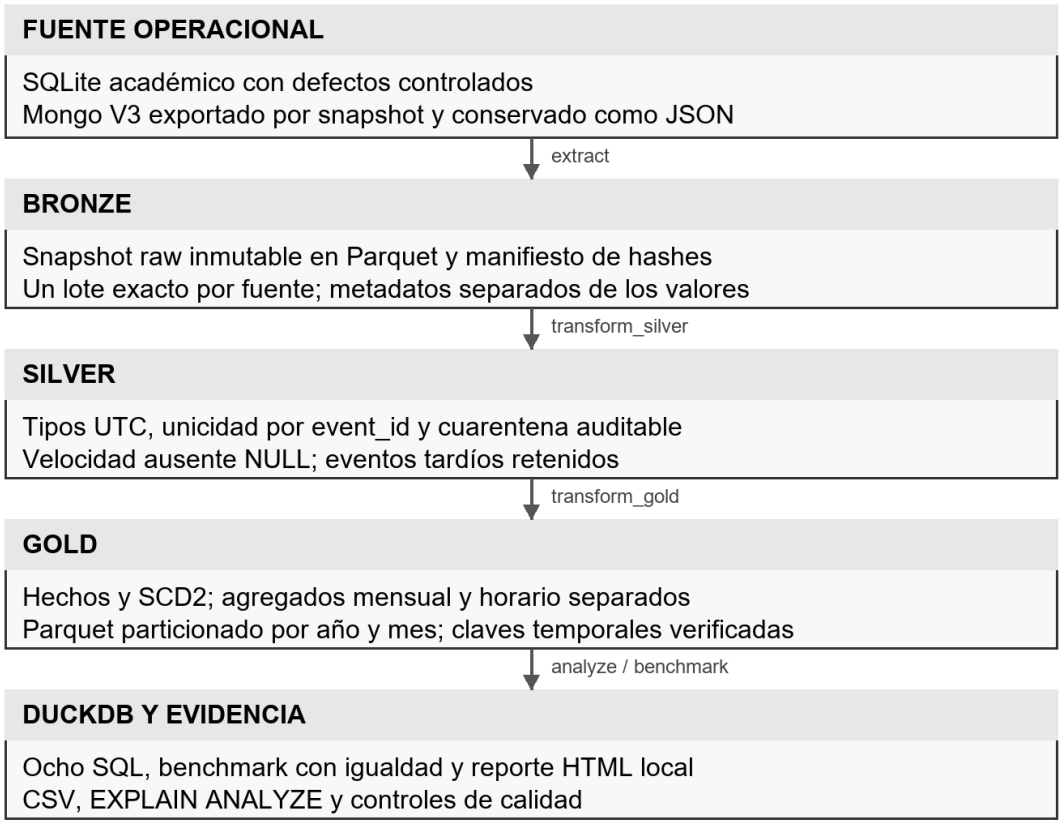
La rúbrica DOCX muestra Peso 20% en los cinco criterios, pero sus encabezados y la tabla de la guía usan 25%, 20%, 20%, 10% y 25%. Esta entrega atiende todos los criterios y no calcula una calificación con una ponderación ambigua.

La guía práctica establece 20 minutos de exposición; el resumen del módulo indica 15. La guía de laboratorio adjunta ofrece una distribución para ambos tiempos. dbt es opcional en la guía práctica y no se exige para ejecutar el perfil base.

GitHub es un entregable obligatorio. El proyecto local y el ZIP están preparados para publicar, con documentación y reglas de exclusión. El equipo debe crear su repositorio remoto y verificar la clonación antes de la entrega; no se ha publicado un repositorio externo.

Arquitectura del laboratorio

Medallion local y separación de responsabilidades



Transversal: calidad, catálogo y Git. Delta es una rama experimental no validada.

Python orquesta la extracción y publica archivos. DuckDB ejecuta tipado, validación, joins y SQL analítico. Parquet ofrece almacenamiento columnar abierto; la tabla estrella constituye el mart analítico, mientras Bronze retiene el snapshot raw.

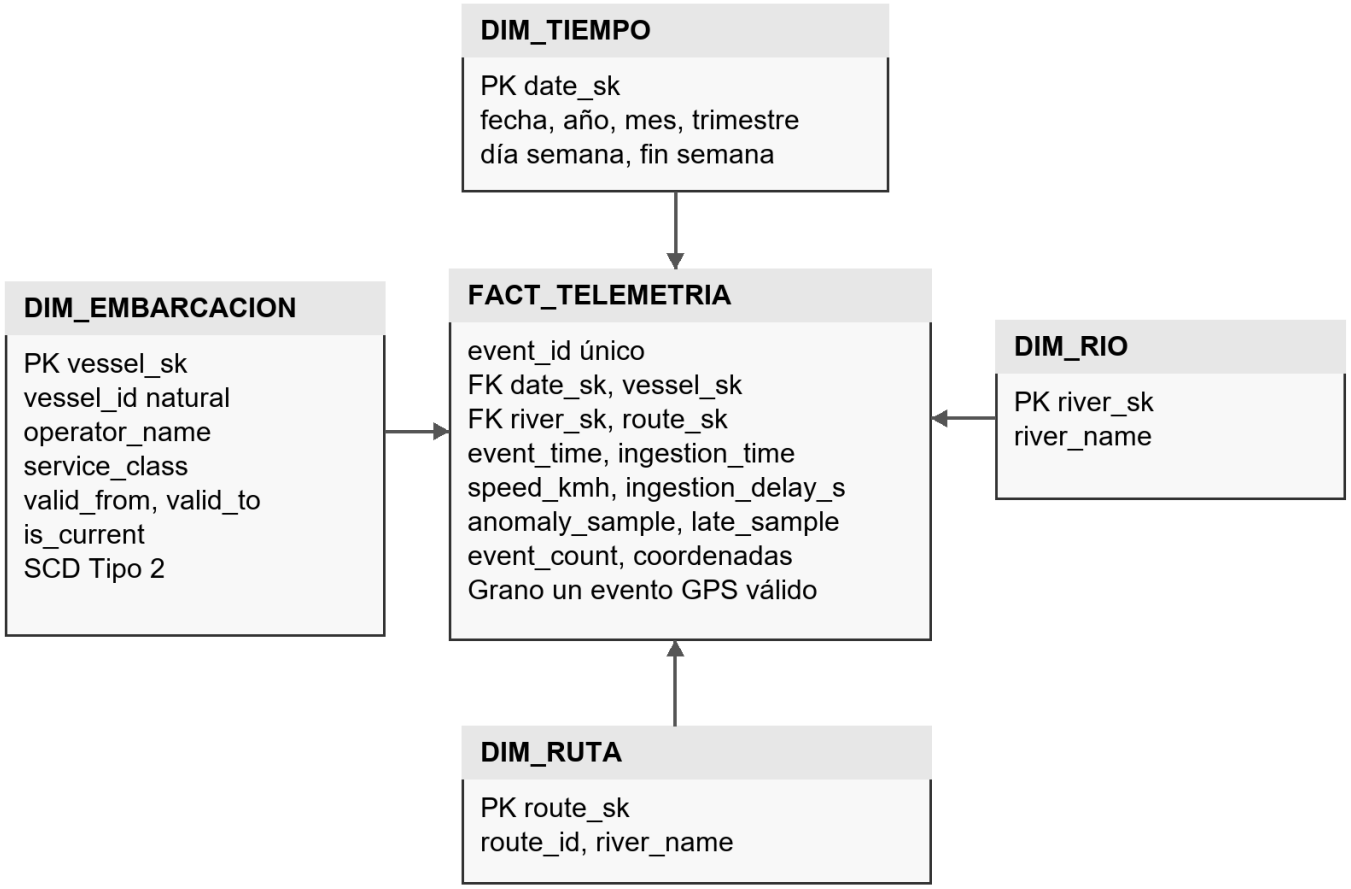
Perfil	Fuente y propósito
Académico base	SQLite real con muestras sintéticas; ejecución y benchmark local
V3 exportada	Mongo snapshot a JSONL y espejo SQLite; integración de eventos
Mongo medido	Adaptador opcional que consulta el motor V3 y compara su propio Gold

La captura raw antes de la transformación sigue la idea ELT. El proceso combina Python con transformaciones en DuckDB y materializa nuevas capas; no se afirma que use dbt. La analítica es batch sobre snapshots, sin garantías de latencia de tracking.

Parquet y carpetas satisfacen el mini-lakehouse pedagógico solicitado. Los manifiestos controlan publicaciones locales con un escritor, pero no sustituyen el log transaccional ni los commits entre tablas de un formato Delta o Iceberg. Esa diferencia determina la evolución de producción.

Modelo estrella atómico

Cuatro dimensiones y claves de acceso analítico



FACT_TELEMETRIA contiene event_id único, claves date_sk, vessel_sk, river_sk y route_sk, tiempos de captura/recepción, secuencia, coordenadas y medidas. event_id actúa como dimensión degenerada de auditoría. No se mezcla una lectura GPS con una fila agregada por hora o mes.

DIM_TIEMPO tiene una fila por fecha UTC. DIM_RIO y DIM_RUTA contextualizan la muestra. La referencia geométrica del corredor permanece en Silver y produce la medida de desviación del hecho. No se interpreta como una cartografía certificada.

DIM_EMBARCACION separa el identificador natural vessel_id de la clave surrogate vessel_sk. Una embarcación puede tener varias claves históricas. Los intervalos SCD se resuelven con event_time; ingestion_time no decide el operador histórico.

AGG_RIO_MES se guarda como tabla adicional con grano año, mes y río. Una agregación de nueve filas puede acelerar una consulta mensual, pero no sustituye el hecho atómico para investigar un evento o cambiar las reglas.

El nuevo AGG_EMBARCACION_HORA usa hora UTC, versión SCD, río y ruta. En el perfil grande resume 496.989 hechos en 8.000 filas; conserva numeradores y denominadores para no promediar medias desiguales.

Historia SCD y medidas

Una implementación temporal verificable

SCD Tipo 2 implementado

El catálogo académico registra un cambio de Operador A y servicio REGULAR a Operador B y PRIORITARIA el 15 de febrero de 2026 para 80 barcos. Se crea una nueva fila con clave diferente, se cierra la anterior y se conserva una sola versión actual. La clave deriva del barco y el comienzo de vigencia; permanece estable al repetir el pipeline.

TA-001	Vigencia	Hechos asociados
Operador A / REGULAR	Desde 1 enero hasta 15 febrero exclusivo	373
Operador B / PRIORITARIA	Desde 15 febrero inclusive; fin NULL	248

```
event_time >= valid_from
AND (valid_to IS NULL OR event_time < valid_to)
```

El intervalo semiabierto asigna un evento exactamente a medianoche del cambio a la versión nueva. Un evento capturado antes y recibido después del cambio conserva la versión anterior. Las pruebas comprueban ambos lados del límite, unicidad actual y estabilidad de claves.

Cómo agregar sin distorsionar

Medida	Clasificación y uso
event_count y flags	Aditivos: sumar muestras válidas, anómalas o tardías
speed_kmh y delay_s	No aditivos: AVG, percentiles o distribución; no SUM de velocidades
Tasas y percentiles	No aditivos: recalcular con denominadores, no promediar p95
Barcos observados	COUNT DISTINCT por vessel_id; no sumar entre períodos
Coordenadas	Contexto numérico: no sumarlas ni tratarlas como distancia

El agregado conserva speed_sum y speed_count para recomponer la media ponderada. El porcentaje de anomalías se calcula con muestras_anómalas / muestras_totales. La demora por muestra incluye el tiempo de desconexión y no equivale a latencia pura de red.

La V3 no tiene historial de operador: su perfil marca NO_DOCUMENTADO, sin fabricar cambios. Para SCD2 real se necesita un catálogo operacional que conserve cuándo se modificaron los atributos.

Calidad y eventos tardíos

Conciliación de Bronze con Silver

Categoría	Filas de referencia
Bronze total	505.500
Silver retenido	496.989
INVALID_TIME	847
INVALID_COORDINATES	848
MISSING_ID	845
IDENTITY_CONFLICT	996
DUPLICATE_RETRY	4.975
Total descartado	8.511

La conservación se comprueba explícitamente: 505.500 = 496.989 + 8.511. Cada fila descartada mantiene record_id y reason y queda en quarantine.parquet junto a sus valores raw. Las categorías son excluyentes; un reintento defectuoso se cuenta por su defecto y no como duplicado válido.

Políticas de limpieza

Se tipan tiempos a UTC, identificadores y coordenadas. Se rechazan campos obligatorios ausentes, fechas inválidas, valores no finitos, coordenadas fuera de rango, velocidades imposibles y secuencias inválidas. Una velocidad opcional ausente permanece NULL: hay 1.493 muestras sin velocidad y el promedio excluye esas filas.

Entre payloads válidos, si el mismo event_id tiene dos contenidos, se excluyen todas sus versiones para revisión. Los reintentos válidos con igual contenido conservan una sola muestra; ingestion_time, como metadato de llegada, no cambia la identidad del GPS.

No perder historia por llegar tarde

Los eventos con gran demora se conservan y participan en la fecha de captura. late_sample indica un retraso superior a 60 segundos, umbral analítico de este laboratorio. No es un watermark de streaming ni demuestra disponibilidad del enlace: falta un denominador de eventos esperados para calcular pérdida o cobertura temporal.

El reporte de calidad incluye retención 98,3163%, rango de fechas, barcos observados, velocidades válidas y conciliación. En producción se definirían umbrales para detener una publicación según el impacto de los rechazos, conservando su evidencia.

Pipeline y reproducibilidad

Un comando y publicación controlada

```
python main.py
python main.py --rows 500000 --repeats 9
```

Etapa	Resultado y garantía
source	SQLite sintético o espejo de la exportación V3
extract	Snapshot de lectura SQLite; Bronze nuevo o reutilizado por hash
transform_silver	Eventos tipados, unicidad, cuarentena y reporte
transform_gold	SCD2, lookup temporal, hechos y agregado Parquet
analyze	8 CSV, SQL aplicado y EXPLAIN ANALYZE
benchmark	Igualdad, muestras de tiempo, medianas y planes
publish	current.json activo después de finalizar controles

Idempotencia que se puede mostrar

El identificador Bronze depende del contenido de la fuente y su catálogo, no de la hora del proceso. Un lote existente se verifica por hashes y se reutiliza. Silver y Gold pertenecen a un build versionado; el cache comprueba los hashes antes de reutilizarlo. Las consultas se abren sobre el snapshot exacto, nunca sobre todos los lotes.

El ensayo V2 de 500.000 originales terminó en 150,918 segundos y el rápido de 50.000 en 17,606 segundos. La idempotencia se comprobó mediante dos ejecuciones del mismo fixture en la suite. La versión V2 cambió el muestreo temporal: sus tiempos no se comparan con V1 como si solo hubiera cambiado una optimización.

Errores y concurrencia

Una excepción guarda failure.json y devuelve error. El puntero activo anterior permanece disponible. Un lock rechaza pipelines simultáneos; una salida normal lo retira. Una interrupción abrupta puede dejar el lock y requiere confirmar que no haya otro proceso antes de retirarlo.

Las siete pruebas base locales cubren extremo a extremo e idempotencia, versiones ambiguas, límite temporal SCD, bloqueo simultáneo, fallo sin pérdida de publicación y preservación del documento V3. El último caso usa un fixture y no acredita una conexión Docker real.

Preguntas analíticas del dominio

Ocho consultas con decisiones y denominadores explícitos

SQL	Pregunta	Uso del resultado
Q1	¿Cuántas muestras y anomalías hay por río y mes?	Detectar cambios de perfil y carga de revisión
Q2	¿Cómo se distribuye la demora captura-recepción?	Priorizar capacidad y recuperación; p95 y p99
Q3	¿Cómo se comparan rutas en velocidad y anomalías?	Revisar corredores y calidad de la muestra
Q4	¿Qué embarcaciones concentran muestras anómalas?	Proponer una lista de revisión contextualizada
Q5	¿Qué hechos pertenecen a cada versión del barco?	Demostrar historia de operador mediante SCD2
Q6	¿Cuántos tardíos y barcos se observan por captura?	Diagnosticar días que requieren revisión
Q7	¿Cómo resumir embarcación-hora sin sesgar medias?	Sumas y conteos ponderados; horas distintas
Q8	¿Qué rutas concentran retrasos de llegada?	p50, p95, p99 y porcentaje tardío

Ejemplo de consulta temporal

```
SELECT v.vessel_id, v.operator_name,
       v.valid_from, v.valid_to,
       COUNT(f.event_id) AS muestras
FROM dim_embarcacion v
LEFT JOIN fact_telemetria f
  ON f.vessel_sk = v.vessel_sk
WHERE v.vessel_id = 'TA-001'
GROUP BY v.vessel_id, v.operator_name,
         v.valid_from, v.valid_to
ORDER BY v.valid_from;
```

Los ocho SQL completos están en queries/. Cada ejecución conserva sus resultados CSV y el plan. Q4 exige al menos 20 muestras por barco para evitar destacar tasas basadas en uno o dos registros. Ese umbral es pedagógico y debe justificarse según el caso real.

Las medidas reflejan observaciones del dataset. No se suman los barcos de varios días para afirmar tamaño de la flota; se usa el identificador natural aunque tenga varias claves SCD. Las muestras anómalas no son incidentes independientes y no constituyen evidencia de delito.

Benchmark medido y comparable

Referencia local 29b53ff4affb del 18 de octubre de 2026

Comparación	Antes ms	Después ms	Ratio
SQLite fuente / DuckDB Gold	3.525,896	122,478	28,79
Monolítico / particionado	10,806	15,158	0,71
Detalle / agregado mensual	89,393	11,238	7,95

Los valores son medianas de nueve repeticiones. Ratio = tiempo antes / tiempo después; un ratio menor que uno significa que la segunda opción resultó más lenta. La población analítica es idéntica: 496.989 eventos válidos. Se comprueba la igualdad del agregado y de cada comparación antes de aceptar tiempos.

Método experimental

Conexiones abiertas, un hilo DuckDB, resultados materializados con fetchall, caché caliente y orden alternado por repetición. Las muestras individuales, mínimos, medianas, versiones y SQL aplicado se guardan en benchmark.json, benchmark.csv y benchmark_queries.sql. ETL, preparación de IDs y escritura del agregado quedan fuera del cronómetro.

Entorno: Windows 11 AMD64, Python 3.12.14, DuckDB 1.5.6, pandas 3.0.1, PyArrow 26.0.0 y SQLite 3.53.1. No se vació la caché del sistema operativo; no es un ensayo de lectura fría ni de concurrencia de usuarios.

Qué explica el primer ratio

SQLite recorre su fuente por filas, selecciona los record_id aceptados y convierte valores para calcular la misma regla de anomalía. Gold ya contiene tipos y métricas derivadas. DuckDB también usa ejecución vectorizada y proyección columnar. La comparación mide esas decisiones en conjunto: no atribuye todo el 28,79 a Parquet.

La fuente base es SQLite real, no MongoDB. El perfil importado también mide un espejo SQLite. El adaptador benchmark_mongo_v3 permite medir el motor real con los mismos eventos; durante esta preparación Docker no estaba activo y no existe una medición Mongo nueva.

En un ensayo pequeño de 1.600 originales DuckDB fue más lento que SQLite: costo fijo de abrir vistas y archivos. El informe conserva ese límite; no selecciona cifras únicamente para mostrar superioridad.

Optimización y lectura de planes

Dos intervenciones medidas con resultados distintos

Particionar y filtrar por año y mes

FACT_TELEMETRIA se escribe en carpetas year=2026/month=1, 2 y 3. La consulta filtra febrero y lee una de las tres particiones. El control usa un Parquet monolítico con las mismas filas y un orden físico equivalente. Los planes documentan el filtro de archivos y la proyección.

```
READ_PARQUET
Projections: anomaly_sample, late_sample
File Filters: (month = 2)
Scanning Files: 1/3
Total Files Read: 1
Rows del resultado de scan: 99398
```

La mediana particionada fue 15,158 ms frente a 10,806 ms. Saltar archivos ocurre correctamente, pero el monolítico ordenado ya permite descartar grupos de filas. Tres archivos pequeños y sus metadatos pueden costar más. No se concluye que el particionado siempre falle: se concluye que no conviene sobreparticionar este volumen.

Preparar un agregado mensual

AGG_RIO_MES reduce 496.989 hechos a nueve filas con numeradores y denominadores. La consulta mensual de conteos y anomalías conserva el resultado exacto. La mediana pasó de 89,393 a 11,238 ms, ratio 7,95. La tabla no sirve para investigar una posición ni calcular un percentil exacto a partir de otra distribución.

Se paga la preparación en transform_gold. Con datos tardíos debe reconstruirse el mes afectado y publicarse una nueva versión; con reglas nuevas puede requerirse relectura de Silver. Promedios ponderados se recomponen con suma / cantidad, sin promediar promedios.

Por qué usar EXPLAIN ANALYZE

El plan ejecuta la consulta y muestra operadores y cardinalidades observadas. El tiempo del plan no reemplaza las nueve medidas de cliente. EXPLAIN QUERY PLAN de SQLite muestra la estrategia de acceso, sin afirmar que sea un perfil de tiempos equivalente a DuckDB.

Mejoras comprobadas de la V2

Resumen horario, visualización local y límites de la profundización

Mejora	Resultado o control
Muestreo académico	Cinco ráfagas por barco con lecturas cada 30 s dentro de cada ventana
Resumen horario	8.000 filas y 496.989 muestras reconciliadas
Analítica	Q7 horario ponderado y Q8 retrasos por ruta
Visualización	Reporte HTML de una corrida; 5 pestañas y filtro
Suite	7 pruebas base aprobadas; 1 Delta opcional omitida

Media ponderada y granularidad

El mart agrupa por hora UTC, vessel_sk, river_sk y route_sk. Una transición SCD o de ruta dentro de una hora puede generar varias filas para el mismo barco; por eso las horas-embarcación se cuentan distintas por identificador natural y hora. Su suma de eventos reconcilia con el detalle.

```
media = SUM(speed_sum) / SUM(speed_count)
porcentaje_tardio = SUM(late_samples) / SUM(event_count)
```

La prueba con velocidades 10, 20 y 40, agrupadas de forma desigual y con un nulo, recupera 23,333; promediar las dos medias produciría 27,5. No se calculan kilómetros multiplicando muestras por un intervalo que no está demostrado.

Reporte sin servicios adicionales

reporte.html conserva resumen, calidad, ocho consultas, benchmark e historia SCD de la corrida validada. Permite filtrar filas y descargar CSV. No ejecuta transformaciones, no necesita un servidor y no tiene refresco automático. Se verificaron estructura y sintaxis; falta ensayar la interacción en el navegador del equipo. Se distingue del panel operativo V3.

Delta con estado transparente

Se preparó un ejercicio aislado de append tardío y versiones 0/1 con deltalake 1.6.6. La escritura local falló con Unable to rename file / Acceso denegado (os error 5). Queda experimental, omitido por defecto y no condiciona main.py. No se declara PASS ni atomicidad entre varias tablas.

Hallazgos y decisiones posibles

Interpretación del dataset sintético de referencia

Río	Anomalías %	Demora p95 s	Demora p99 s
Amazonas	9,040	4.492,899	18.084,471
Putumayo	5,032	2,997	17.898,304
Caqueta	2,935	2,998	17.965,535

Corredores y revisión

Amazonas presenta una proporción de muestras anómalas superior a Putumayo y Caqueta. Esa diferencia fue diseñada en el generador para demostrar análisis; no es un hallazgo sobre navegación real. En producción motivaría revisar corredor, sesgo de muestreo, cobertura de datos y episodios antes de priorizar intervención.

Un p95 puede ocultar la cola

En Putumayo y Caqueta, alrededor del 4,9% de muestras tienen demoras mayores a 60 segundos; el p95 queda cerca de tres segundos aunque el p99 ronda cinco horas. El promedio supera diez minutos. La decisión no debe basarse solamente en p95 global: conviene segmentar por embarcación, ruta y período y observar percentiles más extremos.

Historia de operador

TA-001 conserva 373 muestras bajo Operador A y 248 bajo Operador B. La consulta reconstruye correctamente su contexto histórico. Un contraste de velocidad entre períodos no prueba que el cambio de operador causó una mejora: ruta, carga, nivel del río y cobertura pueden variar.

Qué no permite concluir la muestra

No hay datos de carga, temperatura, combustible ni nivel del río en este laboratorio; no se estiman ingresos, ahorro de combustible ni una optimización hidráulica real. Tampoco hay un manifiesto esperado de todas las capturas para calcular pérdida exacta. Se distinguen muestras anómalas de incidentes y observaciones retenidas de períodos continuos.

La propuesta de producción añade esos datos mediante dimensiones conformadas y hechos de otro grano, conserva unidades y define denominadores de negocio. Antes de una recomendación operativa se valida el modelo y la calidad con datos reales.

Evolución hacia producción

Cambios priorizados a partir de lo que muestra el laboratorio

Responsabilidad	Evolución propuesta
Captura y extracción	Mongo operativo se mantiene; incremental por llegada u offset y corte verificable
Historia de catálogo	Fuente OLTP con cambios efectivos y atributos versionados reales
Almacenamiento	Objeto durable con retención, particiones y compactación según tamaño
Formato de tabla	Iceberg o Delta para snapshots, commits y evolución de esquema
Procesamiento	DuckDB para análisis acotado; evaluar Spark/Trino al crecer volumen y concurrencia
Operación	Orquestación, calidad, frescura, errores, retries y costos medidos
Gobierno	Catálogo, linaje, contratos, dueños y acceso por responsabilidad

La extracción incremental debe avanzar por ingestion_time más un desempate estable, o por offsets de un log. Filtrar solo por event_time perdería capturas antiguas recién recibidas. Conviene solapar ventanas y deduplicar por event_id; avanzar el checkpoint únicamente después de publicar el batch validado.

A la tasa nominal de 800 GPS cada 30 segundos se generan 2.304.000 eventos diarios. Con el supuesto de 1 KiB por evento, son 2,36 GB por día y unos 861 GB al año antes de compresión, índices y réplicas. Los 500.000 originales del ensayo no acreditan ese volumen continuo ni el perfil extremo del enunciado.

Los tardíos pueden afectar meses ya publicados. La política debe regenerar particiones afectadas y revisar hechos cuando llegan cambios SCD retroactivos. La consistencia del hecho y las versiones dimensionales requiere commits coordinados o una publicación de snapshot de aplicación.

Para formatos abiertos, Iceberg favorece interoperabilidad y evolución de particiones; Delta ofrece un log transaccional y capacidades de actualización e historia. La selección requiere probar compatibilidad de lectores, catálogo, operaciones y costos. No se adopta un producto únicamente porque el módulo lo mencione.

Observabilidad: frescura de la última llegada, filas por lote, tasa de rechazos, conflictos, skew por barco, duración de etapas, bytes por archivo y datos pendientes de consolidar. Un tablero analítico puede estar disponible con el último snapshot mientras su frescura es eventual respecto de la fuente.

Seguridad: exportaciones de ubicación restringidas, credenciales fuera del código, acceso mínimo a Bronze y agregados para audiencias generales. Un archivo local no implementa políticas de fila/columna. La replica operativa y la publicación analítica tienen decisiones de disponibilidad y consistencia distintas.

Prioridad inmediata: publicar GitHub, ensayar desde un clon y medir la V3 real. Después: catálogo histórico e incremental. Finalmente: formatos transaccionales y escalamiento, guiados por volumen y necesidades, no por complejidad del stack.

Fuentes y verificación de entrega

Referencias técnicas y estado del laboratorio

Material académico utilizado

Institución Universitaria ITM. Taller 3 Del Operacional al Analítico Construcción de un Mini Lakehouse. Guía paso a paso, 26 páginas. Arquitectura y diseño pp. 4-7; calidad pp. 11-12; consultas y benchmark pp. 17-20; reproducibilidad y rúbrica pp. 21-26.

ITM. Rúbrica de evaluación del Taller 3, DOCX aportado por el equipo. Cinco criterios con indicadores de desempeño. ITM. Module 3 Analytical Ecosystems, documento de 15 páginas; modelado pp. 3-4, zonas p. 7, Lakehouse pp. 8-9, columna/ETL pp. 10-13 y laboratorio pp. 14-15.

Propuestas del equipo: Informe_Actualizado_TrackAmazonas_Mini_Lakehouse_Modulo3.docx, diseño del 15 de octubre; Mina-Lakehouse Copiloto.pdf, 12 páginas; ZIP de código y Parquet; diagrama PNG. Se auditaron sin ejecutar el main externo.

Documentación primaria consultada

DuckDB Lectura de Parquet

DuckDB Particiones Hive

DuckDB Escritura particionada

DuckDB EXPLAIN ANALYZE

Kimball SCD Tipo 2

MongoDB Read concern snapshot

Delta Lake Capacidades y formatos

Apache Iceberg Evolución de esquema y particiones

Qué se entrega y qué debe ejecutar el equipo

Proyecto con código, requisitos fijados, README, ocho consultas, pruebas, comandos, diagramas, diccionario, catálogo, matriz de rúbrica y análisis comparativo. Se conservan los ensayos V2 de 500.000 y 50.000 originales. Los grandes Parquet se regeneran con los comandos documentados.

El perfil base está probado y la repetición del fixture no duplica hechos. Las lecturas Docker y el benchmark Mongo requieren una instancia activa. La profundización Delta no quedó validada localmente por un error de renombrado/permisos. No se reutiliza un PASS del Taller 2 ni del ZIP externo para acreditar estos componentes.

Antes de entregar: publicar el repositorio GitHub y comprobar ejecución desde un clon, confirmar el tiempo de exposición y mostrar main.py y dos consultas en vivo. Con esto el equipo puede defender los mecanismos implementados y distinguir su alcance académico de las necesidades de producción.

Delta rs implementación y APIs

Driver DuckDB para Metabase